基于 DINOv3 的无线信号时频图识别：流程搭建与应用实践

阶段性工作汇报 | 汇报人：罗峻峰 | 日期：2026-10-11

一、工作目标

本次工作的目标有两个：

一是跑通：**“信号仿真生成 → 时频分析 → 事件检测与切图 → 数据集构建 → 深度学习分类 → 评测”**的完整工作流程，并保证每一步可复现、结果可核查；

二是学习并实践： DINOv3 在非自然图像领域（无线电时频图）的应用方法，即利用冻结的预训练视觉特征配合轻量分类头完成 CW / 2FSK / LFM 三分类。

二、主要完成工作

整体工作分为数据生成、时频预处理、特征迁移训练和评估验证四个阶段（图 1）。

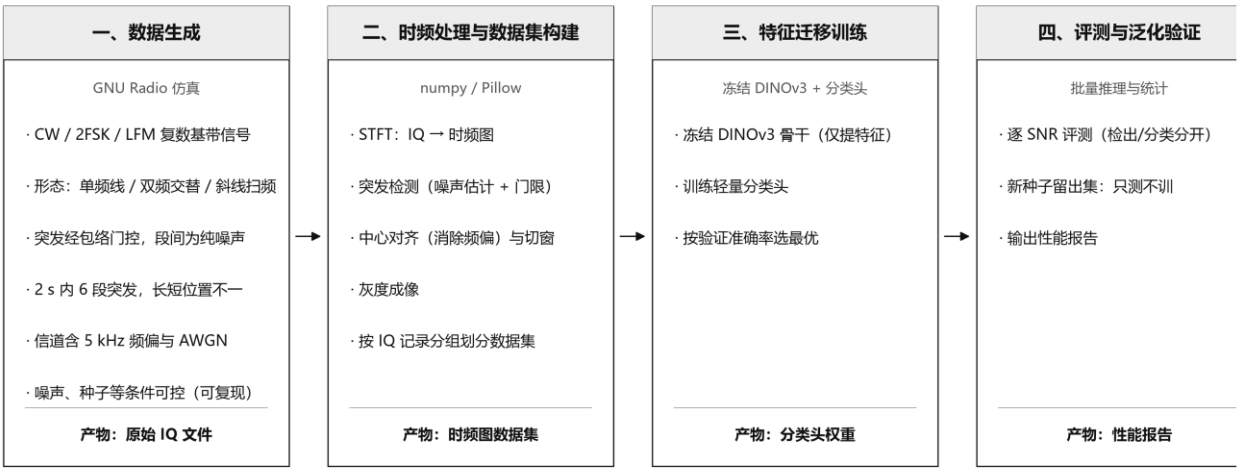


图 1　系统整体工作流程

1. 信号仿真与生成

工具：GNU Radio、Python

- **信号类型与时频形态：**CW 单频线、2FSK 双频交替、LFM 调频斜线
- **突发模拟：**包络门控；2 s 内 6 段不定长、非连续突发，段间为噪声
- **信道条件：**5 kHz 频偏、AWGN、可控 SNR 与随机种子

产物：可复现的复数基带 IQ 信号。图 2 展示其中 CW 信号的 GNU Radio 仿真框图。

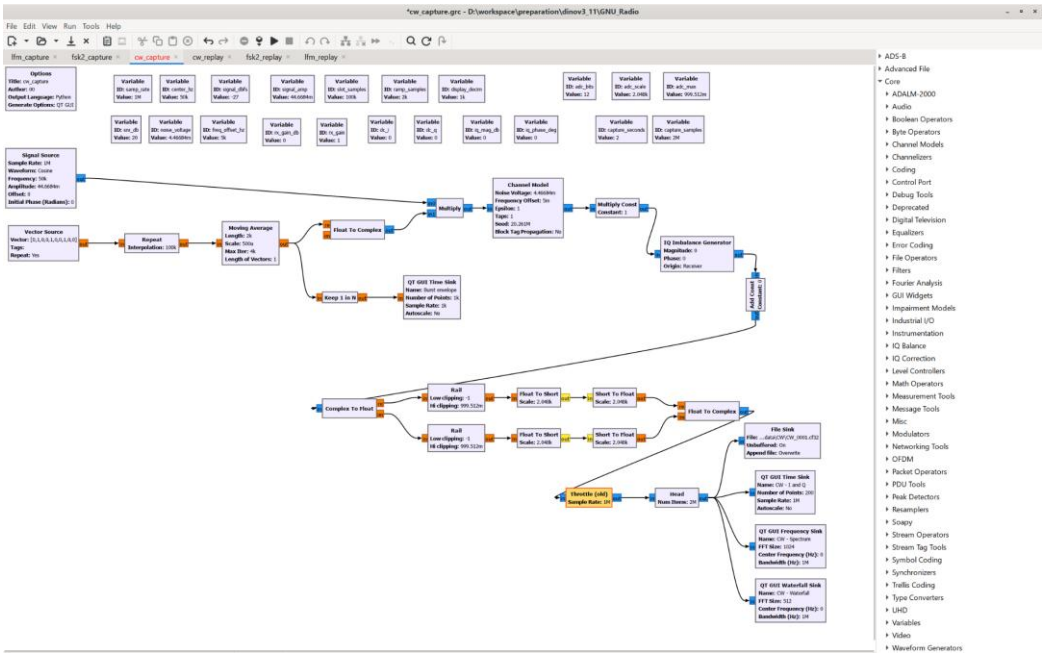


图 2　GNU Radio 中的 CW 信号仿真框图示例

2. 时频处理与数据集构建

工具：NumPy、Pillow

- **STFT：**复数 IQ → 二维时频表示
- **突发检测：**噪声估计与门限判决，定位有效信号片段
- **中心对齐与切窗：**频率中心对齐，统一为定长样本
- **数据构建：**灰度成像，按 IQ 记录分组划分训练/验证/测试集

产物：503 张时频图；训练/验证/测试分别为 305/108/90 张。图 3 为 0 dB 条件下的样本示例。

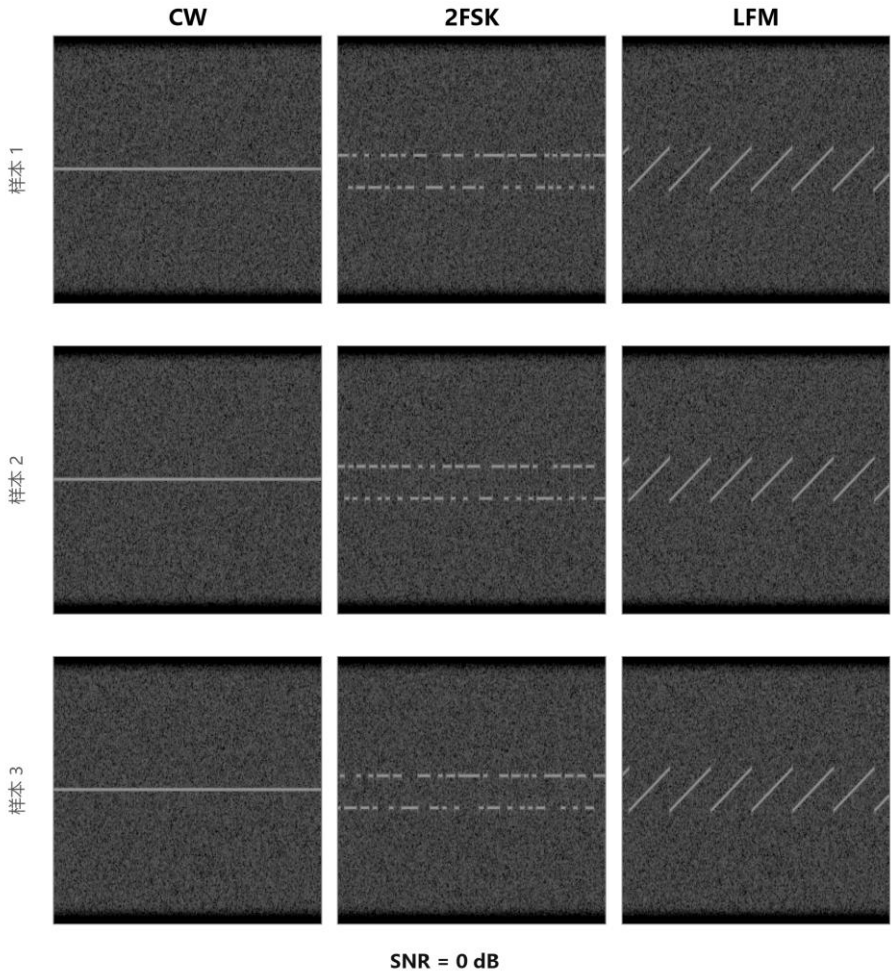


图 3　0 dB 条件下三类信号时频图示例（每类 3 个样本）

3. DINOv3 特征迁移与训练

工具：PyTorch、timm、DINOv3-S/16

- **模型：**vit_small_patch16_dinov3.lvd1689m
- **训练策略：**冻结 DINOv3 骨干；仅训练全连接 → ReLU → Dropout → 全连接分类头
- **输入预处理：**Resize、ToTensor、Normalize；当前条件下分类头约 1 轮收敛

产物：三分类模型及分类头权重。

4. 模型评估与流程验证

工具：Python、自建批量推理评估脚本

- **性能统计：**按类别与 SNR 汇总检出、切图和分类正确数，生成混淆矩阵
- **留出验证：**使用全新噪声种子及 2FSK 比特种子生成数据，只测不训
- **问题定位：**区分检测、切窗损失与分类错误

产物：性能统计与新种子留出测试记录。

三、阶段性成果

- **系统完成：**整个流程跑通，还进行了重构和模块化，方便之后复用；84 条 IQ 记录、503 张时频图
- **低 SNR 现象：**仅用 20 dB 训练时，2FSK 在 −3/−6/−9/−12 dB 下准确率为 33.3%/5.6%/0%/0%

。重新加入混合 SNR 训练后，分类性能明显改善

- **评估结果：**原划分测试集 90/90；新种子留出集 483/483 张分类正确，端到端约 99.4%
- **现存问题：**−12 dB 下偶发突发碎裂，导致部分定长切窗损失

说明：原测试集存在跨 SNR 种子关联；全量诊断包含训练与验证样本，不作为独立泛化成绩。

四、学习收获与思考

收获：

- **DINOv3 与迁移学习：**理解冻结骨干、预训练特征及轻量分类头的配合方式
- **信号处理与数据构建：**实践 STFT、门限检测、频率对齐和定长切窗，认识到预处理质量的重要性

思考和启发：

- **特征与数据增强，自然图像**增强未必适用时频图，因为坐标和一些位置关系都会影响分类结果，所以训练时关闭了随机增强；查资料得到初步结论：**任务决定应保持的特征及可扰动的环境因素。**

进一步思考：能否依据无线信号物理模型设计标签保持的数据增强，提升跨环境泛化能力？